

LN13. 偏差方差的平衡

何 琨

计算机学院数据挖掘与机器学习实验室

华中科技大学 Hopcroft 计算科学研究中心

邮箱: brooklet60@hust.edu.cn

2026 年 4 月



- 1 概念
 - 问题设置
 - 期望标签
- 2 期望测试误差的分解
 - 期望测试误差的分解
 - 方差，偏差与噪声
- 3 检测高偏差和高方差
 - 如何调试机器学习算法
 - 高方差
 - 高偏差

1 概念

- 问题设置
- 期望标签

2 期望测试误差的分解

- 期望测试误差的分解
- 方差，偏差与噪声

3 检测高偏差和高方差

- 如何调试机器学习算法
- 高方差
- 高偏差

假设

- 与通常的设置一样，我们从某个分布 $P(\mathbf{x}, Y)$ 中独立同分布 (i.i.d.) 采样得到一个数据集 $D = (\mathbf{x}_1, y_1) \dots (\mathbf{x}_n, y_n)$ 。
- 在本节中，我们以回归的假设为例，即 $y \in \mathbb{R}$ 。

目标

我们将把分类器的泛化误差分解为三个更容易解释的项。

预备知识

首先，对于任何给定的输入 $\mathbf{x}$ ，可能不存在唯一的标签 y 。

例如，若向量 $\mathbf{x}$ 描述了房子的特征（如：面积，楼层，卧室数，卫生间数，是否有阳光，小区环境打分，周边设施打分，...），而标签 y 为它的价格。可以想象两个描述完全相同的房子，仍然会出现以不同的价格出售。

所以，对于任何给定的特征向量 $\mathbf{x}$ ，在可能的输出标签上有一个分布。由此，给出以下的定义。

期望标签 (考虑 $\mathbf{x} \in \mathbb{R}^d$)

$$\bar{y}(\mathbf{x}) = E_{y|\mathbf{x}}[Y] = \int_{\mathcal{Y}} y \Pr(y | \mathbf{x}) dy.$$

给定特征向量 $\mathbf{x}$ ，期望标签表示期望获得的标签。

第一步，采样得到训练集 D ，由 n 个输入组成，来自 i.i.d. 分布 P 。

第二步，通常在这个数据集上调用一些机器学习算法 $\mathcal{A}$ 来学习一个假设。在形式上，将这个过程表示为： $h_D = \mathcal{A}(D)$ 。

使用算法 $\mathcal{A}$ 在数据集 D 上学习，得到某个学习器 h_D 。

对于给定的 h_D ，可以计算其泛化误差（以均方损失来衡量）如下：

期望测试误差（对给定的 h_D ）

$$E_{(\mathbf{x}, y) \sim P} [(h_D(\mathbf{x}) - y)^2] = \int_{\mathbf{x}} \int_y (h_D(\mathbf{x}) - y)^2 \Pr(\mathbf{x}, y) \partial y \partial \mathbf{x}.$$

注：1) 也可以使用其他损失函数。

2) 我们使用均方损失，因为它有很好的数学性质，也是最常见的损失函数。

对于给定的训练集 D ，上述解释是适用的。

但是，值得注意的是， D 本身是从 P^n 中提取的，因此是一个随机变量。
 h_D 是 D 的函数，因此也是一个随机变量。
因此，我们可以计算它的期望：

期望分类器 (给定 $\mathcal{A}$)

$$\bar{h} = E_{D \sim P^n} [h_D] = \int_D h_D \Pr(D) \partial D.$$

其中 $\Pr(D)$ 是从 P^n 中抽取 D 的概率， $\bar{h}$ 是函数的加权平均值。

使用 h_D 是一个随机变量的事实，计算给定 $\mathcal{A}$ 的基于数据集 D 的期望测试误差。

期望测试误差 (给定 $\mathcal{A}$)

$$E_{\substack{(\mathbf{x}, y) \sim P \\ D \sim P^n}} [(h_D(\mathbf{x}) - y)^2] = \int_D \int_{\mathbf{x}} \int_y (h_D(\mathbf{x}) - y)^2 P(\mathbf{x}, y) P(D) d\mathbf{x} dy dD.$$

注意： D 是训练集， $(\mathbf{x}, y)$ 是测试点。

该表达式评估了机器学习算法 $\mathcal{A}$ 相对于数据分布 $P(X, Y)$ 的质量。

下面将把这个表达式分解为三个有意义的项。

1 概念

- 问题设置
- 期望标签

2 期望测试误差的分解

- 期望测试误差的分解
- 方差，偏差与噪声

3 检测高偏差和高方差

- 如何调试机器学习算法
- 高方差
- 高偏差

期望测试误差的分解

$$\begin{aligned} & E_{\mathbf{x},y,D} \left[[h_D(\mathbf{x}) - y]^2 \right] \\ = & E_{\mathbf{x},y,D} \left[[(h_D(\mathbf{x}) - \bar{h}(\mathbf{x})) + (\bar{h}(\mathbf{x}) - y)]^2 \right] \\ = & E_{\mathbf{x},D} \left[(\bar{h}_D(\mathbf{x}) - \bar{h}(\mathbf{x}))^2 \right] + 2E_{\mathbf{x},y,D} \left[(h_D(\mathbf{x}) - \bar{h}(\mathbf{x})) (\bar{h}(\mathbf{x}) - y) \right] + E_{\mathbf{x},y} \left[(\bar{h}(\mathbf{x}) - y)^2 \right] \end{aligned}$$

期望测试误差的分解

$$E_{x,D} \left[(\bar{h}_D(\mathbf{x}) - \bar{h}(\mathbf{x}))^2 \right] + 2E_{x,y,D} \left[(h_D(\mathbf{x}) - \bar{h}(\mathbf{x})) (\bar{h}(\mathbf{x}) - y) \right] + E_{x,y} \left[(\bar{h}(\mathbf{x}) - y)^2 \right]$$

上式的中间一项为 0，因为：

$$\begin{aligned} E_{x,y,D} \left[(h_D(\mathbf{x}) - \bar{h}(\mathbf{x})) (\bar{h}(\mathbf{x}) - y) \right] &= E_{x,y} \left[E_D \left[h_D(\mathbf{x}) - \bar{h}(\mathbf{x}) \right] (\bar{h}(\mathbf{x}) - y) \right] \\ &= E_{x,y} \left[(E_D [h_D(\mathbf{x})] - \bar{h}(\mathbf{x})) (\bar{h}(\mathbf{x}) - y) \right] \\ &= E_{x,y} [(\bar{h}(\mathbf{x}) - \bar{h}(\mathbf{x})) (\bar{h}(\mathbf{x}) - y)] \\ &= E_{x,y} [0] \\ &= 0 \end{aligned}$$

期望测试误差的分解

回到之前的表达式，我们还有两项：

$$E_{\mathbf{x},y,D} [(h_D(\mathbf{x}) - y)^2] = \underbrace{E_{\mathbf{x},D} [(h_D(\mathbf{x}) - \bar{h}(\mathbf{x}))^2]}_{\text{方差 (Variance)}} + E_{\mathbf{x},y} [(\bar{h}(\mathbf{x}) - y)^2]$$

将上式中的第二项分解如下：

$$\begin{aligned} E_{\mathbf{x},y} [(\bar{h}(\mathbf{x}) - y)^2] &= E_{\mathbf{x},y} [(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x})) + (\bar{y}(\mathbf{x}) - y)^2] \\ &= \underbrace{E_{\mathbf{x},y} [(\bar{y}(\mathbf{x}) - y)^2]}_{\text{Noise}} + \underbrace{E_{\mathbf{x}} [(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))^2]}_{\text{Bias}^2} + 2E_{\mathbf{x},y} [(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))(\bar{y}(\mathbf{x}) - y)] \end{aligned}$$

期望测试误差的分解

$$\underbrace{E_{x,y} [(\bar{y}(\mathbf{x}) - y)^2]}_{\text{Noise}} + \underbrace{E_x [(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))^2]}_{\text{Bias}^2} + 2E_{x,y}[(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))(\bar{y}(\mathbf{x}) - y)]$$

上式中的第三项为 0，因为：

$$\begin{aligned} E_{x,y}[(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))(\bar{y}(\mathbf{x}) - y)] &= E_x [E_{y|\mathbf{x}}[\bar{y}(\mathbf{x}) - y](\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))] \\ &= E_x [E_{y|\mathbf{x}}[\bar{y}(\mathbf{x}) - y](\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))] \\ &= E_x [(\bar{y}(\mathbf{x}) - E_{y|\mathbf{x}}[y])(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))] \\ &= E_x[(\bar{y}(\mathbf{x}) - \bar{y}(\mathbf{x}))(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))] \\ &= E_x[0] \\ &= 0 \end{aligned}$$

期望测试误差的分解

期望测试误差的分解

综上，可将期望测试误差分解如下：

$$\underbrace{E_{\mathbf{x},y,D} [(h_D(\mathbf{x}) - y)^2]}_{\text{Expected Test Error}} = \underbrace{E_{\mathbf{x},D} [(h_D(\mathbf{x}) - \bar{h}(\mathbf{x}))^2]}_{\text{Variance}} + \underbrace{E_{\mathbf{x},y} [(\bar{y}(\mathbf{x}) - y)^2]}_{\text{Noise}} + \underbrace{E_{\mathbf{x}} [(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))^2]}_{\text{Bias}^2}$$

$$\underbrace{E_{\mathbf{x},y,D} [(h_D(\mathbf{x}) - y)^2]}_{\text{Expected Test Error}} = \underbrace{E_{\mathbf{x},D} [(h_D(\mathbf{x}) - \bar{h}(\mathbf{x}))^2]}_{\text{Variance}} + \underbrace{E_{\mathbf{x},y} [(\bar{y}(\mathbf{x}) - y)^2]}_{\text{Noise}} + \underbrace{E_{\mathbf{x}} [(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))^2]}_{\text{Bias}^2}$$

方差 (Variance)

- 捕获在不同的训练集上训练时分类器的变化量。
- 考查所学习的分类器对特定的训练集有多“过度特化” “over-specialized”? 即过拟合 (overfitting)。
- 如果我们有针对当前训练集的最好的模型，则与“平均”分类器的差距有多大?

偏差 (Bias)

$$\underbrace{E_{\mathbf{x}, y, D} [(h_D(\mathbf{x}) - y)^2]}_{\text{Expected Test Error}} = \underbrace{E_{\mathbf{x}, D} [(h_D(\mathbf{x}) - \bar{h}(\mathbf{x}))^2]}_{\text{Variance}} + \underbrace{E_{\mathbf{x}, y} [(\bar{y}(\mathbf{x}) - y)^2]}_{\text{Noise}} + \underbrace{E_{\mathbf{x}} [(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))^2]}_{\text{Bias}^2}$$

偏差


- 即使有无限的训练数据，分类器的固有误差是多少？
- 这是由于分类器“偏向”于一种特定的解决方案（例如线性分类器）。
- 换句话说，偏差是模型固有的。

$$\underbrace{E_{\mathbf{x},y,D} [(h_D(\mathbf{x}) - y)^2]}_{\text{Expected Test Error}} = \underbrace{E_{\mathbf{x},D} [(h_D(\mathbf{x}) - \bar{h}(\mathbf{x}))^2]}_{\text{Variance}} + \underbrace{E_{\mathbf{x},y} [(\bar{y}(\mathbf{x}) - y)^2]}_{\text{Noise}} + \underbrace{E_{\mathbf{x}} [(\bar{h}(\mathbf{x}) - \bar{y}(\mathbf{x}))^2]}_{\text{Bias}^2}$$


噪声

- 数据的固有噪声有多大？
- 这个误差度量的是数据分布和特征表征的不确定性。
- 你无法消除这些错误，这是数据本身的特点带来的。

偏差和方差的图形说明。



偏差和方差随模型复杂度的变化




偏差和方差随模型复杂度的变化。这类似于过拟合和欠拟合的概念。更复杂的模型容易过拟合，而最简单的模型容易欠拟合。

- 1 概念
 - 问题设置
 - 期望标签
- 2 期望测试误差的分解
 - 期望测试误差的分解
 - 方差，偏差与噪声
- 3 检测高偏差和高方差
 - 如何调试机器学习算法
 - 高方差
 - 高偏差


如何调试机器学习算法

如果分类器表现不佳 (例如, 测试或训练误差太高), 有几种方法可以提高性能。要找出合适的对应方法, 第一步是确定问题的根源。



随着训练样本数量的增加, 测试和训练误差的表现

训练与测试误差



上图展示了训练误差和测试误差，可以分为两个主要的区域。

- Regime #1(图的左侧): 训练误差低于期望的误差阈值 (用 ϵ 表示), 但测试误差明显过高。
- Regime #2(图的右侧): 测试误差非常接近训练误差, 但两者都高于期望的容忍值 ϵ 。


高方差

Regime #1 (高方差)

在第一种情况下，效果不好的原因是高方差。

症状

- ① 训练误差远低于测试误差
- ② 训练误差小于 ϵ
- ③ 测试误差高于 ϵ




如何解决高方差

症状

- ① 训练误差远低于测试误差
- ② 训练误差小于 ϵ
- ③ 测试误差高于 ϵ

措施

- 添加更多的训练数据
- 降低模型的复杂性——复杂的模型容易产生高方差
- Bagging (稍后将在课程中讨论)
- 增加正则项




Regime #2 (高偏差)

高偏差

第二种情况表明存在高偏差：所使用的模型不够鲁棒，无法产生准确的预测。

症状

- 1 训练误差大于 ϵ




如何解决高偏差

症状

- 训练误差大于 ϵ

措施

- 使用更复杂的模型 (例如, 核化, 使用非线性模型)
- 添加更多的特征
- Boosting (稍后将在课程中讨论)
- 减少正则项



The End